

线性回归的最小二乘估计公式

二级结论

条件

条件 1（线性相关假定）：

给定成对样本数据 (x_i, y_i) ($i = 1, 2, \dots, n$) 满足线性相关关系，且 $\sum_{i=1}^n (x_i - \bar{x})^2 \neq 0$ 。

结论

结论一（最小二乘公式）：

直观描述：用样本数据计算回归系数的最小二乘估计。

$$\hat{b} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{a} = \bar{y} - \hat{b}\bar{x}$$

推广结论（过样本中心）：

直观描述：回归直线必经过数据点的均值中心。

$$\bar{y} = \hat{b}\bar{x} + \hat{a}$$

理解说明

一句话直觉

最小二乘法通过最小化所有数据点到回归直线的垂直距离平方和，确定最优斜率和截距。

核心拆解

要点一（协方差结构）：

斜率公式的分子是 x 与 y 的离差乘积之和，反映两者线性协同变化；分母是 x 的离差平方和，反映 x 的变异程度。

要点二（截距回代）：

由样本中心点 $(\bar{x}, \bar{y})$ 满足回归方程，得 $\hat{a} = \bar{y} - \hat{b}\bar{x}$ 。

几何本质（最小化原理）

在二维平面中，回归直线是所有可能直线中使得各点纵向距离（即 $|y_i - \hat{y}_i|$ ）平方和最小的直线。

代数意义（偏导推导）

构造目标函数 $Q(a, b) = \sum_{i=1}^n (y_i - a - bx_i)^2$ ，分别对 a 和 b 求偏导并令为零，得到正规方程组，解出 $\hat{b}$ 和 $\hat{a}$ 。

考点价值（高频考点）

- **考法一（求回归方程）**：给出原始数据 (x_i, y_i) ，计算 $\bar{x}, \bar{y}, \sum (x_i - \bar{x})(y_i - \bar{y}), \sum (x_i - \bar{x})^2$ ，代入公式计算 $\hat{b}, \hat{a}$ 。
- **考法二（补全参数）**：已知回归方程过中心点 $(\bar{x}, \bar{y})$ ，结合部分统计量反求未知系数或预测值。

顿悟点

由 $\hat{a} = \bar{y} - \hat{b}\bar{x}$ 直接得到回归直线经过 $(\bar{x}, \bar{y})$ ，因此样本中心点始终在拟合直线上，无需额外检验。

使用场景

- **场景一（完整数据）**：当给定成对样本值且满足线性相关时，直接套用公式计算回归方程。
- **场景二（部分统计量）**：已知 $n, \bar{x}, \bar{y}, \sum x_i^2, \sum x_i y_i$ 等统计量，可选用等价公式 $\hat{b} = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2}$ 。

证明

思路提示

利用最小二乘原理：使所有数据点到直线的纵向距离平方和最小，即最小化 $Q(a, b) = \sum_{i=1}^n (y_i - a - bx_i)^2$ 。分别对 a 和 b 求偏导并设为零，得到正规方程组，求解即得公式。

正式推导

步骤一（目标函数）：

定义平方和函数 $Q(a, b) = \sum_{i=1}^n (y_i - a - bx_i)^2$ 。

理由： Q 衡量所有样本点与直线 $y = a + bx$ 的纵向偏离程度，最小二乘法即选择 a, b 使 Q 达到最小。

步骤二（对 a 偏导）：

计算 $\frac{\partial Q}{\partial a} = -2 \sum_{i=1}^n (y_i - a - bx_i)$ ，令其为零得 $\sum_{i=1}^n (y_i - a - bx_i) = 0$ 。

理由：由极值必要条件，偏导数为零。上式等价于 $\sum y_i - na - b \sum x_i = 0$ 。

步骤三（解出 a 表达式）：

由 $\sum y_i - na - b \sum x_i = 0$ 得 $na = \sum y_i - b \sum x_i$ ，即 $a = \bar{y} - b\bar{x}$ 。

理由：移项并除以 n ，其中 $\bar{y} = \frac{1}{n} \sum y_i$ ， $\bar{x} = \frac{1}{n} \sum x_i$ 。

步骤四（对 b 偏导）：

计算 $\frac{\partial Q}{\partial b} = -2 \sum_{i=1}^n x_i(y_i - a - bx_i)$ ，设其为零得 $\sum x_i y_i - a \sum x_i - b \sum x_i^2 = 0$ 。

理由：展开求和项 $\sum x_i(y_i - a - bx_i) = \sum x_i y_i - a \sum x_i - b \sum x_i^2$ 。

步骤五（代入 a 并整理）：

将 $a = \bar{y} - b\bar{x}$ 代入步骤四的方程：

$$\sum x_i y_i - (\bar{y} - b\bar{x}) \sum x_i - b \sum x_i^2 = 0.$$

展开得 $\sum x_i y_i - \bar{y} \sum x_i + b\bar{x} \sum x_i - b \sum x_i^2 = 0$ 。

理由：移项使含 b 项与不含 b 项分离：

$$\sum x_i y_i - \bar{y} \sum x_i = b(\sum x_i^2 - \bar{x} \sum x_i).$$

注意到 $\sum x_i = n\bar{x}$ ， $\bar{y} \sum x_i = n\bar{x}\bar{y}$ ，上式化为

$$\sum x_i y_i - n\bar{x}\bar{y} = b(\sum x_i^2 - n\bar{x}^2).$$

因此得到斜率的最小二乘估计

$$\hat{b} = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2}.$$

该形式与输入中用离差表示的形式等价，因为 $\sum (x_i - \bar{x})(y_i - \bar{y}) = \sum x_i y_i - n\bar{x}\bar{y}$ ， $\sum (x_i - \bar{x})^2 = \sum x_i^2 - n\bar{x}^2$ 。

步骤六（截距估计）：

回代步骤三的关系，得

$$\hat{a} = \bar{y} - \hat{b}\bar{x}.$$

理由：直接由步骤三将 $\hat{b}$ 代入 $a = \bar{y} - b\bar{x}$ 即得。

结论回扣

综上所述，最小二乘估计公式为

$$\hat{b} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \hat{a} = \bar{y} - \hat{b}\bar{x},$$

且回归直线 $\hat{y} = \hat{b}x + \hat{a}$ 恒过样本中心点 $(\bar{x}, \bar{y})$ 。

典型例题

例 1 (基础)

题目：给定成对数据 $(1, 2), (2, 3), (3, 5), (4, 6)$ ，求回归直线方程。

解题步骤：

第一步（计算均值）：

$$\text{计算 } \bar{x} = \frac{1}{4}(1 + 2 + 3 + 4) = 2.5, \bar{y} = \frac{1}{4}(2 + 3 + 5 + 6) = 4。$$

理由：样本中心是回归直线的基础。

第二步（计算离差和）：

计算

$$\begin{aligned}\sum (x_i - \bar{x})(y_i - \bar{y}) &= (1 - 2.5)(2 - 4) + (2 - 2.5)(3 - 4) + (3 - 2.5)(5 - 4) + (4 - 2.5)(6 - 4) \\ &= (-1.5)(-2) + (-0.5)(-1) + (0.5)(1) + (1.5)(2) \\ &= 3 + 0.5 + 0.5 + 3 \\ &= 7,\end{aligned}$$

$$\begin{aligned}\sum (x_i - \bar{x})^2 &= (1 - 2.5)^2 + (2 - 2.5)^2 + (3 - 2.5)^2 + (4 - 2.5)^2 \\ &= 2.25 + 0.25 + 0.25 + 2.25 \\ &= 5.\end{aligned}$$

理由：分子分母是公式的组成部分。

第三步（套用公式）：

$$\text{由 } \hat{b} = \frac{7}{5} \text{ 得 } \hat{b} = 1.4; \text{ 由 } \hat{a} = 4 - 1.4 \times 2.5 \text{ 得 } \hat{a} = 0.5。$$

理由：直接代入最小二乘公式。

关键结论：回归直线方程为 $\hat{y} = 1.4x + 0.5$ ，且该直线经过点 $(2.5, 4)$ 。

例 2 (稍变形)

题目：已知某组数据 $n = 5$ ， $\sum x_i = 15$ ， $\sum y_i = 20$ ， $\sum x_i y_i = 70$ ， $\sum x_i^2 = 55$ ，求回归直线方程。

解题步骤：

第一步（计算均值）：

$$\bar{x} = 15/5 = 3, \bar{y} = 20/5 = 4。$$

理由：由总和除以个数。

第二步（计算斜率估计）：

$$\begin{aligned}\hat{b} &= \frac{\sum x_i y_i - n \bar{x} \bar{y}}{\sum x_i^2 - n \bar{x}^2} \\ &= \frac{70 - 5 \times 3 \times 4}{55 - 5 \times 9} \\ &= \frac{70 - 60}{55 - 45} \\ &= \frac{10}{10} \\ &= 1.\end{aligned}$$

理由：使用与离差等价的公式（常用简化计算）。

第三步（计算截距估计）：

$$\begin{aligned}\hat{a} &= \bar{y} - \hat{b} \bar{x} \\ &= 4 - 1 \times 3 \\ &= 1.\end{aligned}$$

理由：回归直线过样本中心点。

关键结论：回归方程为 $\hat{y} = x + 1$ 。

例 3（综合应用）

题目：某产品价格 x （元）与需求量 y （件）的统计数据如下：

x	6	7	8	9	10
y	8	7	6	5	4

求需求量对价格的回归直线方程，并预测当价格为 7.5 元时的需求量。

解题步骤：

第一步（计算均值）：

$$\bar{x} = \frac{6+7+8+9+10}{5} = 8, \quad \bar{y} = \frac{8+7+6+5+4}{5} = 6。$$

理由：样本中心为后续计算的基础。

第二步（计算离差和）：

计算

$$\begin{aligned}\sum (x_i - \bar{x})(y_i - \bar{y}) &= (6-8)(8-6) + (7-8)(7-6) + (8-8)(6-6) + (9-8)(5-6) + (10-8)(4-6) \\ &= (-2)(2) + (-1)(1) + (0)(0) + (1)(-1) + (2)(-2) \\ &= -4 - 1 + 0 - 1 - 4 \\ &= -10,\end{aligned}$$

$$\begin{aligned}\sum (x_i - \bar{x})^2 &= (6 - 8)^2 + (7 - 8)^2 + (8 - 8)^2 + (9 - 8)^2 + (10 - 8)^2 \\ &= 4 + 1 + 0 + 1 + 4 \\ &= 10.\end{aligned}$$

理由：公式所需。

第三步（套用公式）：

由 $\hat{b} = \frac{-10}{10}$ 得 $\hat{b} = -1$ ；由 $\hat{a} = \bar{y} - \hat{b}\bar{x}$ 代入得 $\hat{a} = 6 - (-1) \times 8$ ，故 $\hat{a} = 14$ 。

理由：代入最小二乘公式。

第四步（回归预测）：

当 $x = 7.5$ 时， $\hat{y} = -1 \times 7.5 + 14$ ，计算得 6.5（件）。

理由：将 x 值代入回归方程即可。

关键结论： 回归直线方程为 $\hat{y} = -x + 14$ ，样本中心点 $(8, 6)$ 在该直线上，价格 7.5 元时需求预测为 6.5 件。

易错提醒

易错点一（分母为零）：

当 $\sum (x_i - \bar{x})^2 = 0$ 时，斜率公式的分母为零，无法计算 $\hat{b}$ ，但部分学生仍强行代入公式得到无意义结果。

正确理解（x 必须变异）：

使用回归直线的前提是自变量 x 的取值不完全相同，即一定有 $\sum (x_i - \bar{x})^2 > 0$ ；否则回归直线不存在（斜率未定义）。

错因分析（忽略假设）：

最小二乘法推导中假设分母非零，实际应用中若 x 无变异则无法拟合，应检查数据质量。

易错点二（变量混淆）：

计算 $\hat{b}$ 时错误地将分子写成 $\sum (y_i - \bar{y})^2$ 或分母写成 $\sum (y_i - \bar{y})^2$ ，导致斜率方向或大小错误。

正确理解（回归方向）：

回归分析中 y 因变量、 x 自变量， $\hat{b}$ 公式分子是 x 离差与 y 离差的乘积之和，分母是 x 离差平方和，不可对调。

错因分析（概念不清）：

混淆了相关系数与回归系数的定义，或是将 x 与 y 的地位等同。

易错点三（过点误解）：

误以为回归直线一定经过某个原始数据点 (x_i, y_i) ，从而用该点求回归方程。

正确理解（过中心点）：

回归直线唯一确定经过样本中心 $(\bar{x}, \bar{y})$ ，但不一定经过任意观测点。

错因分析（直观错觉）：

由于直线拟合数据，学生直觉认为它应穿过数据点，但最小二乘法只保证整体误差最小而非经过某点。

结论小结**一句话核心**

最小二乘估计公式为 $\hat{b} = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$ ， $\hat{a} = \bar{y} - \hat{b}\bar{x}$ ，所得回归直线必过样本中心 $(\bar{x}, \bar{y})$ 。

使用条件

- **条件 1（线性相关）：**变量 x 与 y 存在线性相关关系（至少大致呈直线趋势）。
- **条件 2（ x 有变异）：**自变量 x 的取值不完全相同，即 $\sum(x_i - \bar{x})^2 > 0$ ，保证分母非零。

关键提醒

- **易错点（分母非零）：**使用公式前必须确认 x 有变异，否则回归无意义。
- **检查项（计算顺序）：**按“均值 $\rightarrow$ 离差积和 $\rightarrow \hat{b} \rightarrow \hat{a}$ ”顺序计算，避免代错。