

样本相关系数 (Pearson r)

二级结论

条件

条件 1 (样本要求):

样本数据为 $(x_1, y_1), \dots, (x_n, y_n)$, 其中 $n \geq 3$; 散点图呈现大致线性趋势, 且无明显异常值。

结论

结论一 (相关系数定义):

直观描述: 衡量两变量线性相关程度的指标, 取值范围为 $[-1, 1]$ 。

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}, \quad r \in [-1, 1].$$

常见推论 (完全线性相关):

直观描述: 当所有样本点落在同一条直线上时, 相关系数绝对值为 1。

$$|r| = 1 \iff y_i = ax_i + b, \quad i = 1, \dots, n.$$

理解说明

一句话直觉

相关系数通过比较每对数据偏离各自平均数的方向是否一致, 来衡量线性关系的强弱。

核心拆解

要点一 (协方差含义):

分子 $\sum (x_i - \bar{x})(y_i - \bar{y})$ 称为样本协方差。若 x 和 y 大多同时偏大或偏小, 则乘积为正, 协方差正; 否则为负。绝对值大小反映同向变化的强度。

要点二 (标准化作用):

分母将协方差除以两个变量各自波动程度的乘积, 使得结果无量纲且限制在 $[-1, 1]$ 内, 方便比较不同尺度的变量之间的相关性。

几何本质 (向量夹角余弦)

将样本中心化后的向量 $\tilde{\mathbf{x}} = (x_1 - \bar{x}, \dots, x_n - \bar{x})$ 和 $\tilde{\mathbf{y}} = (y_1 - \bar{y}, \dots, y_n - \bar{y})$ 视为 n 维空间中的两个向量, 则相关系数 r 正是这两个向量夹角的余弦值:

$$r = \frac{\tilde{\mathbf{x}} \cdot \tilde{\mathbf{y}}}{\|\tilde{\mathbf{x}}\| \|\tilde{\mathbf{y}}\|} = \cos \theta.$$

夹角 θ 越接近 0° (r 接近 1) 表示两向量方向越一致, 线性正相关越强; θ 接近 180° (r 接近 -1) 表示方向相反, 线性负相关越强; $\theta = 90^\circ$ ($r = 0$) 表示两向量正交, 无线性相关。

代数意义 (标准化协方差)

r 是 x 与 y 的样本协方差分别除以各自样本标准差得到的标准化量, 即

$$r = \frac{s_{xy}}{s_x s_y},$$

其中 $s_{xy} = \frac{1}{n-1} \sum (x_i - \bar{x})(y_i - \bar{y})$ (有的定义用 n), s_x, s_y 为样本标准差。这种标准化使得 r 不受单位影响。

考点价值 (高考常见)

- **考法一 (计算相关系数):** 给出几对数据, 直接代入公式计算 r , 并判断正负和强弱。
- **考法二 (解释相关系数):** 给出 r 的值, 描述变量间的线性相关程度, 或根据 r 的大小选择回归模型。

顿悟点

相关系数只关心“线性”关系。即使 $r = 0$, 变量之间仍可能存在完美的非线性关系 (如二次函数)。不要因为 r 小就认定两变量无关。

使用场景

- **场景一 (初步探索):** 在回归分析之前, 先计算 r 粗略判断线性关系是否明显, 若 $|r|$ 接近 1 则适合做线性回归。
- **场景二 (结果验证):** 建立回归方程后, 可计算样本 r 来评估线性拟合的效果。

证明

思路提示

利用柯西-施瓦茨不等式直接导出 $|r| \leq 1$, 同时从等号成立条件得到 $|r| = 1$ 的几何意义。

正式推导

步骤一 (构造两个向量):

令

$$\mathbf{u} = (x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x}), \quad \mathbf{v} = (y_1 - \bar{y}, y_2 - \bar{y}, \dots, y_n - \bar{y}).$$

理由: 相关系数的分子恰好是 $\mathbf{u}$ 与 $\mathbf{v}$ 的内积, 分母是它们模长的乘积。

步骤二（应用柯西-施瓦茨不等式）：

对任意两个 n 维实向量 $\mathbf{u}, \mathbf{v}$ ，有

$$|\mathbf{u} \cdot \mathbf{v}| \leq \|\mathbf{u}\| \|\mathbf{v}\|,$$

即

$$\left| \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \right| \leq \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

理由：柯西不等式是基本不等式，直接给出内积绝对值与模长乘积的关系。

步骤三（除以分母得 $|r| \leq 1$ 并讨论等号）：

将上式两边除以分母（分母 > 0 ，因为 $n \geq 3$ 且数据有变异），得

$$\frac{\left| \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \right|}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \leq 1,$$

即 $|r| \leq 1$ 。

理由：由步骤二的不等式直接变形。

取等条件：柯西不等式等号成立当且仅当 $\mathbf{u}$ 与 $\mathbf{v}$ 线性相关，即存在常数 λ 使得

$$x_i - \bar{x} = \lambda(y_i - \bar{y}) \quad (\forall i),$$

等价于所有样本点 (x_i, y_i) 落在一条直线上。此时 $|r| = 1$ 。

结论回扣

我们证明了 $r \in [-1, 1]$ ，且 $|r| = 1$ 的充要条件是样本点共线。 r 的正负由分子 $\sum (x_i - \bar{x})(y_i - \bar{y})$ 的符号决定，分子为正则 $r > 0$ （正相关），分子为负则 $r < 0$ （负相关）。

典型例题**例 1（基础）**

题目：某产品产量 x （件）与成本 y （元）的 4 组数据如下：

x	1	2	3	4
y	2	4	5	7

计算产量与成本的样本相关系数 r ，并判断相关方向。

解题步骤：

第一步 (计算样本均值):

$$\bar{x} = \frac{1+2+3+4}{4} = 2.5, \quad \bar{y} = \frac{2+4+5+7}{4} = 4.5.$$

理由: 相关系数公式中需要每个数据减去各自均值, 必须先算出均值。

第二步 (计算偏差乘积与平方和):

列表或直接求和:

$$\begin{aligned}\sum (x_i - \bar{x})(y_i - \bar{y}) &= (-1.5)(-2.5) + (-0.5)(-0.5) + (0.5)(0.5) + (1.5)(2.5) = 8, \\ \sum (x_i - \bar{x})^2 &= (-1.5)^2 + (-0.5)^2 + (0.5)^2 + (1.5)^2 = 5, \\ \sum (y_i - \bar{y})^2 &= (-2.5)^2 + (-0.5)^2 + (0.5)^2 + (2.5)^2 = 13.\end{aligned}$$

理由: 公式要求计算这些和。

第三步 (代入公式得 r):

$$r = \frac{8}{\sqrt{5 \times 13}} = \frac{8}{\sqrt{65}} \approx 0.992 > 0.$$

理由: 直接套用相关系数定义式。

关键结论: 产量与成本的相关系数 $r \approx 0.992$, 接近 1, 表明两者呈强烈的正线性相关, 即产量增加成本也随之增加。

例 2 (稍变形)

题目: 某次考试中, 10 名学生的数学成绩和物理成绩的相关系数 $r = 0.87$, 散点图显示数据点大致分布在一条直线附近。请回答: 数学与物理成绩的相关方向和强弱; 能否认为物理成绩完全由数学成绩决定? 为什么?

解题步骤:**第一步 (判断符号与大小):**

$r = 0.87 > 0$, 且 $|r| = 0.87$ 接近 1, 所以正相关且较强。

理由: $r > 0$ 为正相关, $|r|$ 越接近 1 线性相关越强。

第二步 (理解完全相关条件):

完全线性相关要求 $|r| = 1$, 这里 $0.87 < 1$, 所以不是完全决定。

理由: 只有所有点共线时 $|r|$ 才等于 1, 因此物理成绩不是完全由数学成绩决定。

第三步（补充说明）：

相关系数只度量线性关系，即使 $r = 0.87$ 也不能说明因果关系，物理成绩还可能受其他因素影响。

理由： 相关关系不蕴涵因果关系。

关键结论： 数学与物理成绩呈强正线性相关，但物理成绩不完全由数学决定，还需考虑其他因素。

例 3（综合应用）

题目： 某公司为研究广告投入 x （万元）与销售额 y （万元）的关系，收集了 8 个月的数据，计算得相关系数 $r_1 = 0.92$ ；同时，产品质量评分 z 与销售额的相关系数 $r_2 = 0.35$ 。假设两组数据均满足线性趋势且无明显异常值。根据以上信息回答：（1）指出 x 与 y 的相关方向和强度；（2）能否认为销售额完全由广告投入决定？为什么？（3）若希望提高销售额，应优先增加广告投入还是提高产品质量？请说明理由。

解题步骤：**第一步（分析相关方向与强度）：**

$r_1 = 0.92 > 0$ ，且非常接近 1，说明广告投入与销售额呈强正线性相关。

理由： $r > 0$ 为正相关， $|r|$ 越接近 1 线性相关越强。

第二步（判断是否完全决定）：

完全线性相关要求 $|r| = 1$ ，这里 $0.92 < 1$ ，所以销售额不完全由广告投入决定，还受其他因素影响。

理由： 只有样本点全部共线时 $|r|$ 才等于 1。

第三步（比较相关性优先）：

比较 r_1 和 r_2 的大小： $|r_1| > |r_2|$ ，表明广告投入与销售额的线性关联强于产品质量与销售额的关联。因此在资源有限时，优先增加广告投入更可能带来销售额的线性增长（但不能保证因果关系）。

理由： 相关系数绝对值大小反映线性相关强度，可作为决策参考。

关键结论： 广告投入与销售额强正相关，但不能完全决定；广告投入比产品质量对销售额的线性影响更显著。

易错提醒**易错点一（忽略线性前提）**

不考查散点图就直接计算相关系数，认为 r 一定能衡量相关性。

正确理解（先看散点图）：

计算 r 前必须先画散点图确认线性趋势，如果数据呈曲线形状， r 可能接近 0 但实际存在强非线性关系。

错因分析（误用指标）：

将相关系数视为万能的相关指标，忽略了它只度量线性相关这一前提。

易错点二（误解 $r = 0$ ）

认为 $r = 0$ 说明两变量毫无关系。

正确理解（无线性相关）：

$r = 0$ 只表示两变量不存在线性相关，它们之间仍可能存在函数关系（如二次函数）。

错因分析（忽略“线性”二字）：

将“线性相关”简化为“相关”，导致对 r 的错误解读。

易错点三（混淆相关与因果）

认为 $|r|$ 较大就意味着一个变量导致另一个变量变化。

正确理解（相关不蕴涵因果）：

强相关可能由潜在混杂因素造成，或仅为巧合，不能直接推断因果关系。

错因分析（逻辑盲目）：

受直观感受误导，忽略了相关分析与因果分析的本质区别。

结论小结**一句话核心**

样本相关系数 r 刻画两变量的线性相关程度，取值范围在 $[-1, 1]$ ， $|r|$ 越大线性关系越强。

使用条件

- 条件 1（样本要求）： $n \geq 3$ ，散点图大致线性，无异常值。
- 条件 2（变异要求）： x 和 y 均有样本变异（分母非零）。

关键提醒

- 易错点（先看散点图）：计算 r 前必须确认线性趋势，否则结果无意义。

- 检查项 (计算结果): r 一定在 $[-1, 1]$ 内, 若 $|r| > 1$ 说明计算错误。