

独立性检验卡方统计量公式

二级结论

条件

条件 1（随机样本条件）：

数据来自两个分类变量 A, B 的随机样本。

条件 2（期望频数条件）：

各单元格期望频数均不小于 5，且总频数 $n \geq 40$ 。

条件 3（原假设条件）：

原假设 H_0 为两个分类变量 A 与 B 相互独立。

结论

结论一（卡方统计量）：

直观描述：通过观测频数与期望频数的差距衡量独立性。

$$\chi^2 = \frac{n(ad - bc)^2}{(a + b)(c + d)(a + c)(b + d)}$$

近似服从自由度为 1 的 χ^2 分布。

推广结论（等价形式）：

直观描述：卡方值等于各单元格残差平方与期望之比的和。

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

其中 O_{ij} 为实际频数， E_{ij} 为期望频数。

理解说明

一句话直觉 卡方统计量度量实际观测与独立假设下期望之间的整体偏离程度，偏离越大，越不支持独立假设。

核心拆解

要点一（构造思想）：

将每个单元格的观测值与期望值之差平方，再除以期望值，以消除量纲并给偏离较大的单元格更高权重。

要点二（自由度意义）：

在 2×2 列联表中，固定行合计与列合计后，只有一个单元格可以自由变化，

所以近似卡方分布的自由度为 1。

几何本质（残差平方和） 卡方统计量是各单元格标准化残差 $((O - E)/\sqrt{E})$ 的平方和，反映观测点与独立模型在多维空间中的欧氏距离。

代数意义（交叉乘积差）

$$\chi^2 = \frac{n(ad - bc)^2}{(a + b)(c + d)(a + c)(b + d)}$$

表明关联程度完全由交叉乘积差 $ad - bc$ 决定。

考点价值（常见考法）

- **考法一（列联表计算）**：给出 2×2 列联表数值，直接代入公式求 χ^2 值。
- **考法二（等价公式运用）**：利用 $\chi^2 = \sum \frac{(O-E)^2}{E}$ 计算，常在期望频数已给或需验证公式时考查。

顿悟点 只要记住 $ad - bc$ 决定了关联方向和强度，卡方值与 $(ad - bc)^2$ 成正比，且样本量 n 放大效应。

使用场景

- **场景一（独立性检验）**：判断两个分类变量（如性别与选科）是否独立。
- **场景二（一致性检验）**：比较不同群体的分布是否一致（本质相同）。

证明

思路提示 从定义 $\chi^2 = \sum \frac{(O-E)^2}{E}$ 出发，先求出各单元格的期望频数，计算残差，提出公因子后利用代数恒等式化简，得到简洁公式。

正式推导

步骤一（建立符号与残差）：

设 $R_1 = a + b, R_2 = c + d, C_1 = a + c, C_2 = b + d, n = R_1 + R_2 = C_1 + C_2$ 。
计算各单元格残差：

$$\begin{aligned} a - E_{11} &= \frac{ad - bc}{n}, & b - E_{12} &= -\frac{ad - bc}{n}, \\ c - E_{21} &= -\frac{ad - bc}{n}, & d - E_{22} &= \frac{ad - bc}{n}. \end{aligned}$$

理由：利用期望公式 $E_{11} = R_1 C_1 / n$ 等，代入化简即得。

步骤二（写出每项平方与期望比值）：

$$\frac{(a - E_{11})^2}{E_{11}} = \frac{(ad - bc)^2}{n^2 E_{11}}, \quad \frac{(b - E_{12})^2}{E_{12}} = \frac{(ad - bc)^2}{n^2 E_{12}},$$

$$\frac{(c - E_{21})^2}{E_{21}} = \frac{(ad - bc)^2}{n^2 E_{21}}, \quad \frac{(d - E_{22})^2}{E_{22}} = \frac{(ad - bc)^2}{n^2 E_{22}}.$$

理由：将残差平方并代入期望，注意到每个分子都含有 $(ad - bc)^2$ 。

步骤三（提取公因子）：

$$\chi^2 = \frac{(ad - bc)^2}{n^2} \left(\frac{1}{E_{11}} + \frac{1}{E_{12}} + \frac{1}{E_{21}} + \frac{1}{E_{22}} \right).$$

理由：四项累加，公因子 $(ad - bc)^2/n^2$ 提到括号外。

步骤四（计算期望倒数之和）：

将 E_{ij} 表达式代入：

$$\frac{1}{E_{11}} = \frac{n}{R_1 C_1}, \quad \frac{1}{E_{12}} = \frac{n}{R_1 C_2},$$

$$\frac{1}{E_{21}} = \frac{n}{R_2 C_1}, \quad \frac{1}{E_{22}} = \frac{n}{R_2 C_2}.$$

因此

$$\frac{1}{E_{11}} + \frac{1}{E_{12}} + \frac{1}{E_{21}} + \frac{1}{E_{22}} = n \left(\frac{1}{R_1 C_1} + \frac{1}{R_1 C_2} + \frac{1}{R_2 C_1} + \frac{1}{R_2 C_2} \right).$$

理由：由 $E_{ij} = R_i C_j / n$ 得倒数形式。

步骤五（通分合并）：

$$\begin{aligned} \frac{1}{R_1 C_1} + \frac{1}{R_1 C_2} + \frac{1}{R_2 C_1} + \frac{1}{R_2 C_2} &= \frac{R_2 C_2 + R_2 C_1 + R_1 C_2 + R_1 C_1}{R_1 R_2 C_1 C_2} \\ &= \frac{(R_1 + R_2)(C_1 + C_2)}{R_1 R_2 C_1 C_2} \\ &= \frac{n^2}{R_1 R_2 C_1 C_2}. \end{aligned}$$

所以

$$\begin{aligned} \sum_{i,j} \frac{1}{E_{ij}} &= n \cdot \frac{n^2}{R_1 R_2 C_1 C_2} \\ &= \frac{n^3}{R_1 R_2 C_1 C_2}. \end{aligned}$$

理由：通分后分子恰为 $(R_1 + R_2)(C_1 + C_2) = n^2$ 。

步骤六（代入得简洁公式）：

$$\begin{aligned}\chi^2 &= \frac{(ad - bc)^2}{n^2} \cdot \frac{n^3}{R_1 R_2 C_1 C_2} \\ &= \frac{n(ad - bc)^2}{R_1 R_2 C_1 C_2} \\ &= \frac{n(ad - bc)^2}{(a + b)(c + d)(a + c)(b + d)}.\end{aligned}$$

理由：代回 R_1, R_2, C_1, C_2 定义， $R_1 R_2 C_1 C_2 = (a + b)(c + d)(a + c)(b + d)$ 。

结论回扣 通过上述推导，我们从 $\chi^2 = \sum \frac{(O-E)^2}{E}$ 出发，逐步化简得到经典公式，两者完全等价。因此在实际计算中可直接使用较简洁的对角线乘积式。

例 1（基础） 题目： 某校调查性别与选科偏好，数据如下：

	理科	文科
男生	20	10
女生	15	25

计算 χ^2 统计量。 **解题步骤：**

第一步（标注单元格）：

记 $a = 20, b = 10, c = 15, d = 25$ 。

理由：列联表左上、右上、左下、右下对应 a, b, c, d 。

第二步（计算合计数）：

行合计 $R_1 = 30, R_2 = 40$ ；列合计 $C_1 = 35, C_2 = 35$ ； $n = 70$ 。

理由：便于代入公式。

第三步（代入公式计算）：

$$\begin{aligned}\chi^2 &= \frac{70 \times (20 \times 25 - 10 \times 15)^2}{30 \times 40 \times 35 \times 35} \\ &= \frac{70 \times 350^2}{30 \times 40 \times 35 \times 35} \\ &= \frac{8575000}{1470000} \approx 5.833.\end{aligned}$$

理由：直接套用 $\chi^2 = \frac{n(ad-bc)^2}{(a+b)(c+d)(a+c)(b+d)}$ 。

关键结论： $\chi^2 \approx 5.833$ 。

例 2（稍变形） 题目： 某药试验数据如下：

	有效	无效
用药组	30	10
对照组	20	20

利用 $\chi^2 = \sum \frac{(O-E)^2}{E}$ 计算卡方值，并验证与公式 $\chi^2 = \frac{n(ad-bc)^2}{(a+b)(c+d)(a+c)(b+d)}$ 结果一致。 **解题步骤：**

第一步（标注符号与合计）：

$a = 30, b = 10, c = 20, d = 20$ ；行合计 $R_1 = 40, R_2 = 40$ ；列合计 $C_1 = 50, C_2 = 30$ ；
 $n = 80$ 。

理由：建立符号。

第二步（计算期望频数）：

$E_{11} = \frac{40 \times 50}{80} = 25, E_{12} = \frac{40 \times 30}{80} = 15, E_{21} = \frac{40 \times 50}{80} = 25, E_{22} = \frac{40 \times 30}{80} = 15$ 。

理由：期望频数等于行合计乘以列合计除以 n 。

第三步（用定义计算）：

$$\begin{aligned}\chi^2 &= \frac{(30-25)^2}{25} + \frac{(10-15)^2}{15} + \frac{(20-25)^2}{25} + \frac{(20-15)^2}{15} \\ &= \frac{25}{25} + \frac{25}{15} + \frac{25}{25} + \frac{25}{15} \\ &= 1 + \frac{5}{3} + 1 + \frac{5}{3} \\ &= 2 + \frac{10}{3} \\ &= \frac{16}{3} \approx 5.333.\end{aligned}$$

理由：逐项计算后相加。

第四步（用简洁公式验证）：

$$\begin{aligned}\chi^2 &= \frac{80 \times (30 \times 20 - 10 \times 20)^2}{40 \times 40 \times 50 \times 30} \\ &= \frac{80 \times 400^2}{40 \times 40 \times 50 \times 30} \\ &= \frac{12800000}{2400000} \\ &= \frac{16}{3} \approx 5.333.\end{aligned}$$

理由：代入简洁公式得相同结果。

关键结论： $\chi^2 = \frac{16}{3} \approx 5.333$ ，两种方式一致。

例 3（综合应用） 题目： 某研究调查性别与吸烟情况，数据如下：

	吸烟	不吸烟
男性	40	20
女性	10	30

试在 $\alpha = 0.05$ 显著性水平下（临界值 $\chi_{0.05}^2(1) = 3.841$ ）检验性别与吸烟是否独立。 **解题步骤：**

第一步（建立假设）：

H_0 ：性别与吸烟独立； H_1 ：性别与吸烟有关。

理由：独立性检验假设。

第二步（检查期望频数条件）：

计算期望频数： $E_{11} = \frac{60 \times 50}{100} = 30$, $E_{12} = \frac{60 \times 50}{100} = 30$, $E_{21} = \frac{40 \times 50}{100} = 20$, $E_{22} = \frac{40 \times 50}{100} = 20$ 。所有期望频数均大于 5，且 $n = 100 > 40$ ，条件满足。

理由：期望频数均 ≥ 5 ， $n \geq 40$ ，可近似卡方分布。

第三步（计算统计量）：

标注 $a = 40, b = 20, c = 10, d = 30$ ，行合计 $R_1 = 60, R_2 = 40$ ；列合计 $C_1 = 50, C_2 = 50$ ； $n = 100$ 。

$$\begin{aligned}\chi^2 &= \frac{100 \times (40 \times 30 - 20 \times 10)^2}{60 \times 40 \times 50 \times 50} \\ &= \frac{100 \times 10000}{100000000} \\ &= \frac{100}{10} = 10\end{aligned}$$

理由：代入简洁公式。

第四步（比较与结论）：

$16.667 > 3.841$ ，所以拒绝 H_0 ，认为性别与吸烟有关。

理由：卡方值大于临界值，落入拒绝域。

关键结论： $\chi^2 \approx 16.667$ ，拒绝独立假设，认为吸烟与性别相关。

易错提醒

易错点一（忽略使用条件）：

当单元格期望频数小于 5 或 $n < 40$ 时，仍然盲目使用卡方检验。

正确理解（条件必须满足）：

只当各单元格期望频数均 ≥ 5 且 $n \geq 40$ 时，检验统计量才近似服从卡方分布。

错因分析（近似前提不熟）：

忽略近似条件，可能导致错误的显著性结论。

易错点二（位置对应错误）：

将列联表单元格位置搞错，导致代入公式时 a, b, c, d 对应错误。

正确理解（对角乘积差）：

明确 a 为左上， b 右上， c 左下， d 右下，公式中使用的是对角差 $ad - bc$ 。

错因分析（表格方向混淆）：

不按规范顺序填写数据，计算错误。

易错点三（大小判断颠倒）：

误认为卡方值越小越应该拒绝 H_0 。

正确理解（大则拒绝独立）：

卡方值越大，观测与期望偏差越大，越支持拒绝独立假设，即卡方值大于临界值时拒绝 H_0 。

错因分析（假设逻辑不清）：

对检验的拒绝域方向理解错误。

结论小结

一句话核心 卡方统计量通过观测与期望的差异衡量变量间关联程度，值越大越支持相关。

使用条件

- 条件 1（随机样本条件）：数据来自两个分类变量的随机样本。
- 条件 2（期望频数条件）：各单元格期望频数均不小于 5，且总频数 $n \geq 40$ 。
- 条件 3（原假设条件）：原假设 H_0 为两分类变量相互独立。

关键提醒

- 易错点（公式适用条件）：使用前必须检查期望频数是否满足条件，否则近似失

效。

- **检查项（单元格定位）：**务必按列联表左上、右上、左下、右下对应 a, b, c, d ，确保 $ad - bc$ 计算正确。